

Федеральное государственное автономное образовательное учреждение высшего образования «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ «ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

ОТЧЁТ О УЧЕБНОМ ПРОЕКТЕ КУРСА  
Машинное обучение и безопасность систем

# Обнаружение спама комментариев на YouTube

*Трек В1: Обнаружение спама и фишинга в каналах общественной коммуникации  
Инженерные доказательства и отчёт о развертывании производства*

Имя ученика: Ханзада Мубашир Хассан

Имя инструктора/преподавателя: **Силаев Юрий Владимирович**

Учебный год: 2025-2026

Дата подачи: 5 июня 2026 года

*Проверенный базовый стек среды: Python 3.11 | Scikit-Learn | SMOTE | TF-IDF*

# Обнаружение спама комментариев на YouTube

Набор данных: UCI YouTube Spam Collection (лицензия: CC BY 4.0)

Источник: <https://archive.ics.uci.edu/dataset/380/youtube+spam+collection+dataset>

## 1. Краткое содержание

Мы обучаем классификатор TF-IDF + логистической регрессии для обнаружения спам-комментариев. В основной рабочей точке (порог = 0,4457, min\_recall=0,90) точность теста = 84,21%, отзыв = 95,24%, F1 = 0,8939.

## 2. Данные

| Метрика                                  | Ценность  |
|------------------------------------------|-----------|
| Необработанные ряды                      | 1956      |
| Точные дубликаты                         | 196       |
| Использованные ряды (после dedup/dropna) | 1760      |
| Ветчина / Спам (использован)             | 919 / 841 |
| Спам-обмен                               | 47.78%    |
| Размер поезда                            | 1408      |
| Размер теста                             | 352       |
| Средняя длина (символы)                  | 96.3      |
| Средние слова                            | 15.7      |


### 3. Метрики

|                                    | Точность           | Точность           | Вспомнить          | F1                 | balanced_accuracy  | roc_auc |
|------------------------------------|--------------------|--------------------|--------------------|--------------------|--------------------|---------|
| DF + LogReg)                       | 0.8977272727272727 | 0.952054794520548  | 0.8273809523809523 | 0.8853503184713376 | 0.8946687370600415 |         |
| DFE + сбалансированно) @ hr=0.4457 | 0.8920454545454546 | 0.8421052631578947 | 0.9523809523809524 | 0.8938547486033519 | 0.8946687370600415 |         |


### 4. Сюжеты

#### Распределение текста 01


Text distribution (YouTube comments)




## Распределение класса 02



## 03 PR Анализ порога кривой



## 05 матриц путаницы



## 5. Примеры ошибок

ПРИМЕРЫ ОШИБОК (основная рабочая точка)

=====

Порог: 0,4457

Ложноотрицательные результаты (спам, предсказанная ветчина): 8

-----

$p(\text{spam})=0.0575$  | <http://psnboss.com/?ref=2tGgp3pV6L> это песня■

$p(\text{spam})=0.1721$  | Помоги Шакира' S waka waka — первая песня женщины-исполнителя, набравшая 1 миллиард просмотров.<br />(Dark Horse опережает примерно на 100 миллионов просмотров больше, а у Roar всего на 50 миллионов просмотров)<br /><a href="https://w...> $p(\text{spam})=0.3032$  | Чёрт, это был лучший 0687119038 Патрика Ключверта его сына!■  $p(\text{spam})=0.3072$  | Поделитесь этим видео... Эта песня может превзойти PSY - Gangnam Style!

$p(\text{spam})=0.3465$  | Заставьте GWAR сыграть в Супербоуле 2015 <http://www.change.org/petitions/the-national-football-le>

Ague-Allow-Gwar-to-Perform-the-2015-Super-Bowl-halftime-show#Поделиться ■

Ложные срабатывания (прогнозируемый спам): 30

-----

$p(\text{spam})=0.8077$  | Первый комментарий — Чак Норрис явно :D■

$p(\text{spam})=0.7352$  | Я даже больше не смотрю, просто прихожу сюда проверить 2 миллиарда или

not■  $p(\text{spam})=0.5763$  | Просто хочу проверить, сколько просмотров у

неё■  $p(\text{spam})=0.5494$  | Джастин Бибер = гей ■

$p(\text{spam})=0.5420$  | Я хочу врубить этого года парня навсегда■

## 6. Тесты на устойчивость

### Шум персонажей

| noise_level | Вспомнить          | Точность           | F1                 | balanced_accuracy  |
|-------------|--------------------|--------------------|--------------------|--------------------|
| 0%          | 0.9523809523809524 | 0.8421052631578947 | 0.8938547486033519 | 0.8946687370600415 |
| 5%          | 0.9107142857142856 | 0.7611940298507462 | 0.8292682926829267 | 0.8249223602484472 |
| 10%         | 0.8869047619047619 | 0.745              | 0.8097826086956521 | 0.8048654244306418 |
| 15%         | 0.8809523809523809 | 0.6757990867579908 | 0.7648578811369509 | 0.7475414078674948 |
| 20%         | 0.8690476190476191 | 0.6266094420600858 | 0.7281795511221946 | 0.6981107660455487 |
| 30%         | 0.8869047619047619 | 0.5601503759398496 | 0.6866359447004609 | 0.6255175983436853 |

### Дрейф словарного запаса

| drift_level | Вспомнить          | Точность           | F1                 | balanced_accuracy  |
|-------------|--------------------|--------------------|--------------------|--------------------|
| 0%          | 0.9523809523809524 | 0.8421052631578947 | 0.8938547486033519 | 0.8946687370600415 |
| 10%         | 0.9404761904761904 | 0.8404255319148937 | 0.8876404494382023 | 0.8887163561076605 |
| 20%         | 0.9285714285714286 | 0.8387096774193549 | 0.8813559322033899 | 0.8827639751552796 |
| 30%         | 0.9345238095238096 | 0.839572192513369  | 0.8845070422535211 | 0.8857401656314701 |
| 50%         | 0.9107142857142856 | 0.8406593406593407 | 0.8742857142857143 | 0.8765527950310559 |

### Состязательная обфускация

| obfuscation_type     | Вспомнить          | Точность           | F1                 | balanced_accuracy  |
|----------------------|--------------------|--------------------|--------------------|--------------------|
| Интервалы между ними | 1.0                | 0.4926686217008797 | 0.6601178781925344 | 0.529891304347826  |
| Числа                | 0.9583333333333334 | 0.4923547400611621 | 0.6505050505050506 | 0.5280797101449276 |
| смешанный            | 1.0                | 0.4772727272727273 | 0.6461538461538462 | 0.5                |

## 7. Политики и использование ИИ (обязательно)

Безопасная лаборатория / политика по данным: подтверждаю, что не использовал запрещённые данные и соблюдал правила/safe-lab.md и policies/data-policy.md.